### References

- Amiri, R., Mehrpouyan, H., Fridman, L., Mallik, R., Nallanathan, A., & Matolak, D. (2018). A machine learning approach for power allocation in hetnets considering qos. https://doi.org/10.1109/ICC.2018.8422864
- Artstein, R. (2017). Inter-annotator agreement. *Handbook of linguistic annotation* (pp. 297–313). Springer.
- Biewald, L. (2020). Experiment tracking with weights and biases [Software available from wandb.com]. https://www.wandb.com/
- Bird, S., Klein, E., & Loper, E. (2009). Natural language processing with python: Analyzing text with the natural language toolkit. "O'Reilly Media, Inc.".
- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of machine Learning research*, 3(Jan), 993–1022.
- Carifio, J., & Perla, R. J. (2007). Ten common misunderstandings, misconceptions, persistent myths and urban legends about likert scales and likert response formats and their antidotes. *Journal of social sciences*, 3(3), 106-116. https://www.researchgate.net/publication/26619168
- Chaumond, J. (2020). + dbmdz german bert models. https://huggingface.co/dbmdz/bert-base-german-cased
- Collobert, R., Kavukcuoglu, K., & Farabet, C. (2011). Torch7: A matlab-like environment for machine learning. *BigLearn*, *NIPS Workshop*.
- Dang, N. C., Moreno-García, M. N., & De la Prieta, F. (2020). Sentiment analysis based on deep learning: A comparative study. *Electronics*, 9(3), 483. https://doi.org/10.3390/electronics9030483
- Dathathri, S., Madotto, A., Lan, J., Hung, J., Frank, E., Molino, P., Yosinski, J., & Liu, R. (2019). Plug and play language models: A simple approach to controlled text generation. arXiv preprint arXiv:1912.02164. https://doi.org/10.48550/arXiv.1912.02164
- Davies, M., & Fleiss, J. L. (1982). Measuring agreement for multinomial data. *Biometrics*, 38(4), 1047–1051.
- De Silva, M. (2023). Preprocessing steps for natural language processing (nlp): A beginner's guide [Accessed on December 14, 2023]. https://medium.com/@maleeshadesilva21/preprocessing-steps-for-natural-language-processing-nlp-a-beginners-guide-d6d9bf7689c9

- Deep, A. (2020). Word2vec, glove, fast text and baseline word embeddings step by step [Accessed on November 9, 2023]. https://medium.com/analytics-vidhya/word2vec-glove-fast text-and-baseline-word-embeddings-step-by-step-d0489c15d10b
- Delovski, B. (2023). Intro to transformers: The decoder block [Accessed on Oct 26, 2023]. https://www.edlitera.com/blog/posts/transformers-decoder-block#mcetoc\_1gtef7bgt11
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805. https://doi.org/10.48550/arXiv.1810.04805
- Fan, A., Lavril, T., Grave, E., Joulin, A., & Sukhbaatar, S. (2020). Addressing some limitations of transformers with feedback memory. arXiv preprint arXiv:2002.09402. https://doi.org/10.48550/arXiv.2002.09402
- Fan, A., Lewis, M., & Dauphin, Y. (2018). Hierarchical neural story generation. arXiv preprint arXiv:1805.04833. https://doi.org/10.48550/arXiv.1805.04833
- FastText. (n.d.). Fasttext [Accessed on May 15, 2023]. https://fasttext.cc/
- Flesch, R. (1948). A new readability yardstick. *Journal of applied psychology*, 32(3), 221.
- Graves, A. (2013). Generating sequences with recurrent neural networks. arXiv preprint arXiv:1308.0850. https://doi.org/10.48550/arXiv.1308.0850
- Gugger, S. (2020). Distilbert-base-german-cased. https://huggingface.co/distilbert-base-german-cased
- Guhr, O., Schumann, A.-K., Bahrmann, F., & Böhme, H. J. (2020a). Broad-coverage german sentiment classification model for dialog systems [Accessed on May 15, 2023]. https://github.com/oliverguhr/german-sentiment
- Guhr, O., Schumann, A.-K., Bahrmann, F., & Böhme, H. J. (2020b). Training a broad-coverage German sentiment classification model for dialog systems. In N. Calzolari, F. Béchet, P. Blache, K. Choukri, C. Cieri, T. Declerck, S. Goggi, H. Isahara, B. Maegaard, J. Mariani, H. Mazo, A. Moreno, J. Odijk, & S. Piperidis (Eds.), Proceedings of the twelfth language resources and evaluation conference (pp. 1627–1632). European Language Resources Association. https://aclanthology.org/2020.lrec-1.202
- He, X. (2021). Parallel refinements for lexically constrained text generation with bart. arXiv preprint arXiv:2109.12487. https://doi.org/10.48550/arXiv.2109.12487
- Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2019). The curious case of neural text degeneration. arXiv preprint arXiv:1904.09751. https://doi.org/10.48550/arXiv.1904.09751

- Honnibal, M., & Montani, I. (2017). spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing [To appear].
- Hu, Z., Yang, Z., Liang, X., Salakhutdinov, R., & Xing, E. P. (2017). Toward controlled generation of text. *International conference on machine learning*, 1587–1596. https://doi.org/10.48550/arXiv.1703.00955
- Hugging Face. (n.d.-a). https://huggingface.co/
- Hugging Face. (n.d.-b). Perplexity of fixed-length models. https://huggingface.co/docs/transformers/perplexity
- Hugging Face. (n.d.-c). Text classification [Accessed on December 15, 2023]. https://huggingface.co/docs/transformers/tasks/sequence\_classification
- Kann, K., Rothe, S., & Filippova, K. (2018). Sentence-level fluency evaluation: References help, but can be spared! arXiv preprint arXiv:1809.08731. https://doi.org/10.48550/arXiv.1809.08731
- Kapadia, S. (2019). Evaluate topic models: Latent dirichlet allocation (lda) [Accessed on November 26, 2023]. https://towardsdatascience.com/evaluate-topic-model-in-python-latent-dirichlet-allocation-lda-7d57484bb5d0
- Krause, B., Gotmare, A. D., McCann, B., Keskar, N. S., Joty, S., Socher, R., & Rajani, N. F. (2020). Gedi: Generative discriminator guided sequence generation. arXiv preprint arXiv:2009.06367. https://doi.org/10.48550/arXiv.2009.06367
- Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17), 1–5. http://jmlr.org/papers/v18/16-365.html
- Lhoest, Q., Villanova del Moral, A., Jernite, Y., Thakur, A., von Platen, P., Patil, S., Chaumond, J., Drame, M., Plu, J., Tunstall, L., Davison, J., Šaško, M., Chhablani, G., Malik, B., Brandeis, S., Le Scao, T., Sanh, V., Xu, C., Patry, N., ... Wolf, T. (2021). Datasets: A community library for natural language processing. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 175–184. https://aclanthology.org/2021.emnlp-demo.21
- Li, J., Tang, T., Zhao, W. X., Nie, J.-Y., & Wen, J.-R. (2022). Pretrained language models for text generation: A survey. arXiv preprint arXiv:2201.05273. https://doi.org/10.48550/arXiv.2105.10311
- Lipenkova, J. (2022). Choosing the right language model for your nlp use case [Accessed on May 15, 2023]. https://towardsdatascience.com/choosing-the-right-language-model-for-your-nlp-use-case-1288ef3c4929

- Lokare, G. (2023). Preparing text data for transformers: Tokenization, mapping and padding [Accessed on November 7, 2023]. https://medium.com/@lokaregns/preparing-text-data-for-transformers-tokenization-mapping-and-padding-9fbfbce28028
- López Espejel, J. (2022). Understanding greedy search and beam search [Accessed on December 3, 2023]. https://medium.com/@jessica\_lopez/understanding-greedy-search-and-beam-search-98c1e3cd821d
- Manocchio, L. D., Layeghy, S., Lo, W. W., Kulatilleke, G. K., Sarhan, M., & Portmann, M. (2023). Flowtransformer: A transformer framework for flow-based network intrusion detection systems. arXiv preprint arXiv:2304.14746. https://doi.org/10.48550/arXiv.2304.14746
- Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Jia, Y., Rafal Jozefowicz, Lukasz Kaiser, Manjunath Kudlur, ... Xiaoqiang Zheng. (2015). TensorFlow: Large-scale machine learning on heterogeneous systems [Software available from tensorflow.org]. https://www.tensorflow.org/
- Martinez, J. J. (2023). Supervised fine-tuning: Customizing llms. https://medium.com/mantisnlp/supervised-fine-tuning-customizing-llms-a2c1edbf22c3
- McKinney, W. (2010). Data Structures for Statistical Computing in Python. In S. van der Walt & J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a
- Minixhofer, B., Paischer, F., & Rekabsaz, N. (2022). WECHSEL: Effective initialization of subword embeddings for cross-lingual transfer of monolingual language models. Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 3992–4006. https://aclanthology.org/2022.naacl-main.293
- pandas development team, T. (2020). Pandas-dev/pandas: Pandas (Version latest). Zenodo. https://doi.org/10.5281/zenodo.3509134
- Pascual, D., Egressy, B., Bolli, F., & Wattenhofer, R. (2020). Directed beam search: Plug-and-play lexically constrained language generation. arXiv preprint arXiv:2012.15416. https://doi.org/10.48550/arXiv.2012.15416
- Pascual, D., Egressy, B., Meister, C., Cotterell, R., & Wattenhofer, R. (2021). A plugand-play method for controlled text generation. arXiv preprint arXiv:2109.09707. https://doi.org/10.48550/arXiv.2109.09707

- Pecánek, M. (2021). Flesch reading ease: Does it matter for seo? (data study). https://ahrefs.com/blog/flesch-reading-ease/
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., et al. (2011). Scikit-learn: Machine learning in python. *Journal of machine learning research*, 12(Oct), 2825–2830. https://doi.org/10.48550/arXiv.1201.0490
- Pennington, J., Socher, R., & Manning, C. (2014). GloVe: Global vectors for word representation. In A. Moschitti, B. Pang, & W. Daelemans (Eds.), *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)* (pp. 1532–1543). Association for Computational Linguistics. https://doi.org/10.3115/v1/D14-1162
- Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving language understanding with unsupervised learning.
- Rehurek, R., & Sojka, P. (2011). Gensim–python framework for vector space modelling. NLP Centre, Faculty of Informatics, Masaryk University, Brno, Czech Republic, 3(2).
- Reiter, E., & Dale, R. (2002). Building applied natural language generation systems. Natural Language Engineering, 3. https://doi.org/10.1017/S1351324997001502
- Röder, M., Both, A., & Hinneburg, A. (2015). Exploring the space of topic coherence measures. Proceedings of the eighth ACM international conference on Web search and data mining, 399–408. https://doi.org/10.1145/2684822.2685324
- Samuels, A., & Mcgonical, J. (2020). News sentiment analysis. arXiv preprint arXiv:2007.02238. https://arxiv.org/pdf/2007.02238.pdf
- Schmid, H. (1999). Improvements in part-of-speech tagging with an application to german. *Natural language processing using very large corpora* (pp. 13–25). Springer.
- Schmid, H. (2013). Probabilistic part-ofispeech tagging using decision trees. New methods in language processing, 154.
- Schmid, H. (n.d.). Treetagger a part-of-speech tagger for many languages [Accessed on November 9, 2023]. https://www.cis.uni-muenchen.de/~schmid/tools/TreeTagger/
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347.
- Schweter, S. (2020). German gpt-2 model (Version 1.0.0). Zenodo. https://doi.org/10. 5281/zenodo.4275046

- Stewart, M. (2023). Guide to classification on imbalanced datasets [Accessed on November 7, 2023]. https://towardsdatascience.com/guide-to-classification-on-imbalanced-datasets-d6653aa5fa23
- Sun, C., Qiu, X., Xu, Y., & Huang, X. (2019). How to fine-tune bert for text classification? Chinese Computational Linguistics: 18th China National Conference, CCL 2019, Kunming, China, October 18–20, 2019, Proceedings 18, 194–206. https://doi.org/10.48550/arXiv.1905.05583
- SuperAnnotate. (2023). Fine-tuning large language models (llms) in 2023. https://www.superannotate.com/blog/llm-fine-tuning
- Sutton, R. S., & Barto, A. G. (n.d.). Reinforcement learning: An introduction. Bradford Book.
- Textstat. (n.d.). https://pypi.org/project/textstat/
- Tunstall, L., von Werra, L., & Wolf, T. (2022). Natural language processing with transformers. building language applications with hugging face. O'Reilly Media, Inc.
- Vajjala, S., Majumder, B., Gupta, A., & Surana, H. (2020). Practical natural language processing. a comprehensive guide to building real-world nlp systems. O'Reilly Media, Inc.
- Vallat, R. (2018). Pingouin: Statistics in python. The Journal of Open Source Software, 3(31), 1026. https://doi.org/10.21105/joss.01026
- van der Lee, C., Gatt, A., van Miltenburg, E., & Krahmer, E. (2021). Human evaluation of automatically generated text: Current trends and best practice guidelines. Computer Speech & Language, 67, 101151. https://doi.org/10.1016/j.csl.2020. 101151
- van Heeswijk, W. (2022). Proximal policy optimization (ppo) explained [Accessed on November 7, 2023]. https://towardsdatascience.com/proximal-policy-optimization-ppo-explained-abed1952457b
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, & R. Garnett (Eds.), Advances in neural information processing systems. Curran Associates, Inc. https://doi.org/10.48550/arXiv.1706.03762
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental

- Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261–272. https://doi.org/10.1038/s41592-019-0686-2
- von Platen, P. (2020). How to generate text: Using different decoding methods for language generation with transformers [Accessed on November 5, 2023]. https://huggingface.co/blog/how-to-generate
- von Werra, L. (2023). Tune gpt2 to generate controlled sentiment reviews. https://github.com/huggingface/trl/blob/main/examples/notebooks/gpt2-sentiment-control.ipynb
- von Werra, L., Belkada, Y., Tunstall, L., Beeching, E., Thrush, T., Lambert, N., & Huang, S. (2020). Trl: Transformer reinforcement learning. https://github.com/huggingface/trl
- Vujovic, Ž. D. (2021). Classification model evaluation metrics. International Journal of Advanced Computer Science and Applications, 12(6). https://doi.org/10.14569/ IJACSA.2021.0120670
- Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., ... Rush, A. (2020). Transformers: State-of-the-art natural language processing. In Q. Liu & D. Schlangen (Eds.), Proceedings of the 2020 conference on empirical methods in natural language processing: System demonstrations (pp. 38–45). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-demos.6
- Zarrieß, S., Voigt, H., & Schüz, S. (2021). Decoding methods in neural language generation: A survey. *Information*, 12(9), 355. https://doi.org/10.3390/info12090355
- Zhang, H., Song, H., Li, S., Zhou, M., & Song, D. (2022). A survey of controllable text generation using transformer-based pre-trained language models. arXiv preprint arXiv:2201.05337. https://doi.org/10.48550/arXiv.2201.05337
- Zhou, S., Liu, J., Zhong, X., & Zhao, W. (2021). Named entity recognition using bert with whole world masking in cybersecurity domain. 2021 IEEE 6th International Conference on Big Data Analytics (ICBDA), 316–320. https://doi.org/10.1109/ICBDA51983.2021.9403180
- Zhu, L., Xu, Y., Zhu, Z., Bao, Y., & Kong, X. (2022). Fine-grained sentiment-controlled text generation approach based on pre-trained language model. *Applied Sciences*, 13(1), 264. https://doi.org/10.48550/arXiv.2006.09891
- Ziegler, D. M., Stiennon, N., Wu, J., Brown, T. B., Radford, A., Amodei, D., Christiano, P., & Irving, G. (2019). Fine-tuning language models from human preferences. arXiv preprint arXiv:1909.08593. https://doi.org/10.48550/arXiv.1909.08593

## Appendix A Function for Logit Modification

#### Code Listing 5

Logit Modification Mechanism. Adapted from Pascual et al. (2020).

```
indexed_tokens = tokenizer.encode(text)
2 indexed_this_seq = tokenizer.encode(this_sequence)
3 tokens_tensor = torch.tensor([indexed_tokens])
4 tokens_tensor = tokens_tensor.to('cuda')
5 model.to('cuda')
7 outputs = model(tokens_tensor)
8 del tokens_tensor
9 torch.cuda.empty_cache()
11 logits = outputs.logits
12 logits = logits[0, -1, :]/ temperature
   # Calculate cosine similarity
15 logits_pro_guid_word=[]
16 pred_indexes=[]
17 for k,fasttext_word in zip(guide_word_lemma,fasttext_words):
    sim = cosine_similarity(np.reshape(
    fasttext_word, (1, -1)), conv_table_gpt_vocab)
19
20
    if only_max == True:
21
      sim_aux = np.zeros_like(sim)
22
      sim_aux[0,sim.argmax()] = sim.max()
      sim = sim_aux
24
25
      sim = np.clip(np.squeeze(sim), a_min=0, a_max=None)
26
      sim_squared = sim*sim
27
28
   # Modify logits for given keyword
29
    logits_temp = logits + torch.tensor(sim_squared*weight).cuda()
30
    logits_temp = top_p_filtering(logits_temp, top_p=top_p)
31
    logits_temp = F.softmax(logits_temp, dim=-1)
32
33
    predicted_index = torch.multinomial(logits_temp, 1).item()
34
    logits_pro_guid_word.append(logits[predicted_index].item())
35
    pred_indexes.append(predicted_index)
37
   #find best performing keyword and select it as the next word
```

```
39 predicted_index=pred_indexes[np.argmax(logits_pro_guid_word)]
40 predicted_text = tokenizer.decode(indexed_tokens + [predicted_index])
41 this_sequence = tokenizer.decode(indexed_this_seq + [predicted_index])
42 pred_word = predicted_text.split()[-1]
44 pred_word_lemma= tagger.tag_text(pred_word,tagonly=True)
45 pred_word_lemma=[keyword.split('\t')[-1] for keyword in pred_word_stem
     [0]
46
   #control keywords
48 if pred_word_stem in guide_word_lemma:
49
    fasttext_words.pop(guide_word_lemma.index(guide_word_lemma))
50
    guide_word_lemma.remove(guide_word_lemma)
51
52
    if guide_word_lemma==[]:
53
    guide = False
54
```

## Appendix B Beam Search

#### Code Listing 6

Part of Proposed Beam Search. Own Creation

```
for i in range(30):
    count_iteration = 0
    flag_next_gen=True
    while(flag_next_gen):
      while(any(context)):
        for i in range(width_beam):
6
          if guide_next == True:
            tmp_new_context, pred_stem = sample_sentence_old(
                   context[0], tokenizer_gpt, model_gpt,
                   guide_word_lemma,keywords_fasttext,
11
                                      conv_table_gpt_vocab, weight,
12
                                      guide_next, only_max=only_max,
                                      top_p=0.5)
14
15
            context_next_gen.append(tmp_new_context)
16
           else:
             tmp_new_context= sample_sentence_noguide(context[0],
                   tokenizer_gpt, model_gpt)
19
         context_next_gen.append(tmp_new_context)
20
      context.pop(0)
21
22
      context = context_next_gen
23
      context_next_gen = []
24
      count_iteration +=1
25
      if count_iteration == 4:
2.7
         flag_next_gen = False
28
    cleaned_list = [item.split('] ')[1] for item in context]
30
    keywords_weigth = [len(set([word.split('\t')[-1] for word in tagger.
     tag_text(word_tokenize(text, language='german'),tagonly=True)]).
     intersection(set(keywords))) for text in cleaned_list]
    tmp_dict=dict()
33
34
    for text,no_keywords in zip(context,keywords_weigth):
35
      tokenize_input = tokenizer_gpt.tokenize(text)
```

```
tensor_input = torch.tensor([tokenizer_gpt.convert_tokens_to_ids(
37
     tokenize_input)]).to('cuda')
38
      loss, _ = model_gpt(tensor_input, labels=tensor_input)[:2]
39
      perplexity=math.exp(loss)
40
      perplexity_weigted=math.exp(loss)/(no_keywords+1)
41
      tmp_dict[text]=perplexity_weigted
42
43
    sorted_dict=dict(sorted(tmp_dict.items(), key=lambda item: item[1]))
44
     best_entry = list(sorted_dict.items())[0]
45
     context=best_entry[0]
```

# Appendix C Examples of Generated Texts

# C.1 Texts Generated by Different Models with Negative Sentiment Token

#### ORIGINAL TEXT

Die Zimmermädchen und Bedienungen im Restaurant waren sehr nett und sehr bemüht. Der Service an der Rezeption hat uns sehr geärgert. Wir kamen dreimal mit dem gleichen Anliegen und jeder wollte es weitergeben, nur keiner wusste Bescheid und nichts ist passiert. Für eine Umbuchung von einem Zimmer wollten sie dann noch 30 € haben, obwohl wir vorher eine Mail mit unseren Wünschen geschrieben hatten. Im großen und Ganzen war dieser Bereich also sehr! unfreundlich.

#### GPT-2

Die Zimmermädchen und Bedienungen im Restaurant waren sehr nett und zuvorkommend. Das Frühstück war reichhaltig und abwechslungsreich. Es gab verschiedene Kuchen und Torten, die allesamt sehr lecker waren. Die Preise waren sehr günstig und die Bedienung war sehr freundlich. Wir kommen gerne wieder! Wir waren im Oktober 2018 zum 4. Mal in diesem Hotel. Das Hotel ist sehr gut gelegen. Die Zimmer sind sehr groß und die Lage ist gut. Die Angestellten sind sehr freundlich und hilfsbereit. Das Frühstück ist sehr gut und das Personal ist sehr freundlich. Die Lage ist sehr gut. Die Zimmer

#### SFT1

Die Zimmermädchen und Bedienungen im Restaurant waren sehr nett und freundlich. Die Putzfraün waren sehr freundlich und hilfsbereit. Das Essen war nicht abwechslungsreich und hat nicht geschmeckt. Wir haben uns jeden Tag satt gegessen und es war nicht sehr abwechslungsreich. Das Essen war aber nicht schlecht. Die Qualität des Essens war nicht gut. Es gab immer das gleiche. Das Salatbuffet war nicht besonders abwechslungsreich. Die Salate waren nicht besonders lecker. Die Qualität der Speisen war sehr schlecht. Die Cocktails waren nicht sehr gut. Die Zimmerreinigung war auch nicht sehr gut. Es wurde nur oberflächlich

#### SFT1RL1

Die Zimmermädchen und Bedienungen im Restaurant waren sehr nett und bemüht, aber unfreundlich. Man konnte nicht Deutsch, da nur Englisch gesprochen wurde. Man wurde nicht verstanden. Das Essen war eine Zumutung. Es gab nur das selbe, die Auswahl war nicht ausreichend. Die Atmosphäre war schlecht, die Qualität der Speisen schlecht. Es gab nur einen Kellner der sich um die Gäste kümmerte. Das Zimmer

wurde nur oberflächlich gereinigt. Es gab keine Handtücher. Das Bad war dreckig und nicht sauber. Es gab keinen Safe. Der Spiegel war nicht richtig befestigt. Die Zimmer

# C.2 Texts Generated by Different Models with Positive Sentiment Token

#### ORIGINAL TEXT

Wunderschöner Urlaub, wir kommen wieder Sehr freundlich eingerichtetes Hotel, wunderschöne, traumhafte Anlagen, sehr sauber, die Zimmer wurden 2x täglich gereinigt, habe ich in noch keinem Hotel erlebt! Sehr viele Russen, manche konnten sich nicht benehmen, aber das ist ja nur zu gut bekannt... Besonders gefallen haben mir die Poolanlagen, einfach traumhaft! Also ich kann dieses Hotel nur weiter empfehlen und werde auch nächstes Jahr dort wieder zu Gast sein.

#### GPT-2

Wunderschöner Urlaub, wir kommen wieder Sehr freundlich eingerichtetes Hotel, wunderschöne, saubere Zimmer und Frühstück, sehr gutes Preis-Leistungsverhältnis. Für die Region... Sehr schönes Hotel mit tollem Pool und schönen Zimmern. Der Pool ist sehr sauber und hat auch eine Sauna. Die Zimmer sind groß und sehr gemütlich. Wir hatten einen sehr schönen Aufenthalt und kommen wieder. Das Hotel ist wirklich sehr schön und sauber. Die Zimmer sind auch sehr sauber. Die Betten sind sehr bequem. Das Frühstück ist sehr gut und reichhaltig. Die Mitarbeiter sind sehr freundlich und hilfsbereit. Wir kommen gerne wieder.

#### SFT1

Wunderschöner Urlaub, wir kommen wieder Sehr freundlich eingerichtetes Hotel, wunderschöne, gepflegte Anlage, schöne Zimmer, leckeres Essen, sehr freundliches Personal, wir kommen wieder! Alles sehr sauber und gepflegt. Das Essen ist sehr gut und abwechslungsreich. Für uns war es das schönste Hotel auf Rhodos, wir kommen wieder! Wir hatten eine sehr schöne Zeit in diesem Hotel. Die Animation war sehr nett und freundlich. Das Personal war sehr aufmerksam und hilfsbereit. Das Essen war sehr gut und abwechslungsreich. Wir kommen wieder! Die Animation war sehr nett und hilfsbereit. Das Personal ist sehr freundlich und hilfsbereit.

#### SFT1RL1

Wunderschöner Urlaub, wir kommen wieder Sehr freundlich eingerichtetes Hotel, wunderschöne, saubere Zimmer. Das Essen war gut, abwechslungsreich und sehr gut. Das Personal ist sehr nett und hilfsbereit. Wir kommen wieder. Sehr gutes Essen. Es gibt einen schönen Strand. Wir kommen wieder. Das Personal ist sehr nett und hilfsbereit.

Das Essen ist gut. Wir kommen wieder. Sehr gutes Hotel. Das Personal ist sehr freundlich und hilfsbereit. Wir kommen wieder. Sehr gutes Essen. Wir kommen wieder. Sehr gutes Hotel. Das Personal ist sehr freundlich und hilfsbereit. Wir kommen wieder. Sehr gutes Essen.

# Appendix D Survey

Figure 20
Opening Dialog for Demographic Data and Selecting the Path.

Hallo ich bin Paulina, Inh	studiere Applied Information and Data Science an der HSLU. Ich bin in der letzten
Phase meines Studiums durch Künstliche Intellig konkreten Anwendungsf	und arbeite an meiner Masterarbeit. Diese beschäftigt sich mit der Textgenerierung enz bzw. damit wie die Textgenerierung von aussen beeinflusst werden kann. Im fall versuche ich eine bestimmte Grundstimmung (Sentiment) zu erzeugen oder mit sselwörtern zu kombinieren.
Derzeit bin ich dabei die Wörter) zu lesen und ein Umfrage beteiligen, danr Algorithmuses erkennen	Ergebnisgüte zu erfassen. Dazu bitte ich dich 6 verschiedene Texte (jeweils ca. 100 i paar Fragen zu beantworten. Wenn sich ausreichend viele Personen an dieser in kann ich durch einen Vergleich eurer Wahrnehmung Stärken und Schwächen des i. Der Textinhalt wurde nicht nachträglich modifiziert. Die einzigen Korrekturen imen von Sätzen ohne Satzende sowie doppelter Sätze am Ende des Texts.
	min. Die Kombination aus einzelnen Texten mit bestimmten Fragen kann teilweise ein szieren. Daher bitte nicht automatisch auf die "5" klicken.
	echt werden von mir keine weiteren personenbezogenen Daten gespeichert. In der abgeschickte Umfrage nicht korrigiert werden. Jeder Teilnehmer kann sich aber gern
Vielen Dank für deine Un Paulina	nterstützung!
Wie alt bist du?	
unter 30	
zwischen 30 und 40	
zwischen 40 und 60	
○ über 60	
Wähle dein Geschlecht	t
○ Männlich	
O Weiblich	
O Divers	
Wähle eine Farbe aus!	•
○ Gelb	
Grün	

Note: Own Creation

Figure 21
Example of Text Evaluation.

Sekcja 2 z 20						
A1						× i
Wir waren in diesem Hotel. Wir werden das Hotel wieder buchen. Das Essen ist sehr gut und ausreichend. Die Atmosphäre ist toll und das Lobby schrecklich verschließend. Das Personal ist sehr freundlich und hilfsbereit. Man merkt immer wieder das die Gäste sich wohl fühlen. Das Personal ist auch sehr nett und hat uns jeden Tag mit einer netten Art und einem leckeren Essen versorgt. Die Bar im Hotel ist sehr groß und gut. Wir haben uns dort sehr wohl gefühlt und wir würden es immer wieder buchen. Die Zimmer sind einfach nur schön und sauber.						
Dieser Text ist positiv. *						
	1	2	3	4	5	
lch stimme überhaupt nicht zu	0	0	0	0	0	Ich stimme vollkommen zu
Dieser Text ist frei von Rechtschre	eib- und	l Gramm	atikfeh	lern. *		
	1	2	3	4	5	
lch stimme überhaupt nicht zu	0	0	0	0	0	lch stimme vollkommen zu
Dieser Text ist gut strukturiert. *						
	1	2	3	4	5	
lch stimme überhaupt nicht zu	0	0	0	0	0	ich stimme vollkommen zu
Dieser Text ist leicht verständlich.						
	1	2	3	4	5	
ich stimme überhaupt nicht zu	0	0	0	0	0	Ich stimme vollkommen zu
Ein Muttersprachler könnte den T	ext gen	auso ge	schrieb	en habe	en. *	
	1	2	3	4	5	
lch stimme überhaupt nicht zu	0	0	0	0	0	lah stimme vollkommen zu
Dieser Text ergibt Sinn. *						
	1	2	3	4	5	
ich stimme überhaupt nicht zu	0	0	0	0	0	Ich stimme vollkommen zu
Die Übergänge in dem Text sind g	ut gesc	hrieben	*			
	1	2	3	4	5	
lch stimme überhaupt nicht zu	0	0	0	0	0	Ich stimme vollkommen zu

Note: Own Creation

## Appendix E Texts Evaluated in the Survey

In this section texts used for the survey are presented. The texts depicted in red were removed and not displayed to the survey's participants.

A1 Wir waren in diesem Hotel. Wir werden das Hotel wieder buchen. Das Essen ist sehr gut und ausreichend. Die Atmosphäre ist toll und das Lobby schrecklich verschließend. Das Personal ist sehr freundlich und hilfsbereit. Man merkt immer wieder das die Gäste sich wohl fühlen. Das Personal ist auch sehr nett und hat uns jeden Tag mit einer netten Art und einem leckeren Essen versorgt. Die Bar im Hotel ist sehr groß und gut. Wir haben uns dort sehr wohl gefühlt und wir würden es immer wieder buchen. Die Zimmer sind einfach nur schön und sauber.

A2 Wir waren in diesem Hotel. Das Personal war sehr zuvorkommend und freundlich. Auch die Zimmer wurden jeden Tag gründlich gereinigt. Die Bettenkissen waren sehr angenehm und gut Kissen strahlend sauber. Alle vertrauenswürdig und freundlich. Wir hatten Zimmer mit Meerblick. Wir hatten auch ein sehr großes Zimmer. Die Sauberkeit im Bad war sehr gut. Man hatte immer Platz für seine Sachen. Auch das Hotel ist sehr sauber gewesen. Die Zimmer waren sehr sauber, das Personal ist sehr freundlich und hilfsbereit und das Animationsprogramm war sehr gut, das Essen war auch gut. Der

A3 Wir waren in diesem Hotel. Das Hotel ist sehr schön und man fühlt sich sehr wohl. Die Anlage ist sehr gepflegt und sauber. Die Zimmer sind sehr schön und mit allem ausgestattet was man braucht. Wir haben auch einen Eindruck von schrecklich vertrauenswürdigem Essen und Getränken bekommen. Das Hotelpersonal ist nett und man muss sich keine Sorgen machen, man kann alles mit einem Drink trinken. Das Hotel ist auch schön ruhig. Es gibt einen Strand. Und wenn man einen hat, wird man sofort abgeholt. Das Personal ist freundlich, hilfsbereit und hilfsbereit.

B1 Wir waren in diesem Hotel. Das Personal ist nicht freundlich und total unfreundlich, auch das Kissen schrecklich. Wenn man sich beschweren will, dann wird einem das gar nicht erklärt. Ich habe das Hotel gewechselt. Das Hotel ist sehr alt und sehr schmutzig. Handtücher werden nicht gewechselt, obwohl die Gäste in der gleichen Kategorie auch noch die Handtücher aufhängen. Das Essen ist ungenießbar. Die Tische und Stühle sind mit Schimmel verschmiert. Die Getränke werden in Plastikbechern serviert. Das Essen ist auch sehr schlecht. Es gibt nur

**B2** Wir waren in diesem Hotel. Das Zimmer war Bett fröhlich strahlend. Die Dusche war schmutzig. In der Badewanne war Schimmel. Das Bett war nur zusammengeschoben und man konnte nur durch die Zimmergänge laufen. Der Boden im Bad

war dreckig. Schimmel im Bad. Die Betten waren durchgelegen und die Ränder mit schwarzen Flecken. Die Handtücher waren sehr schmutzig. Ich war froh das ich dieses Zimmer gewechselt hatte. Das Bett war nicht in Ordnung. Das Bett wurde nur sehr sporadisch gewechselt. Es stank stark im Raum und es war

B3 Wir waren in diesem Hotel. Die Zimmer waren grausam alt und alt, sie waren nicht einmal sauber. Das Bett war alt und durchgelegen und das Kind fröhlich auf dem Spielplatz. Das Bett war nur mit einem dünnen Tuch oder Lappen zu waschen. Auch das Bad war klein und die Fugen in den Fliesen total durchgelegen. Schimmel auf den Armaturen und auf den Fliesen. Das Bad war sehr dreckig und die Armaturen nicht sauber. Wenn man die Toilettenspülung aus dem Wasserhahn herausdrehen wollte, da kam man sich mit dem Kopf in

C1 Wir waren in diesem Hotel. Das Zimmer war sauber und sehr komfortabel. Die Lage war ideal. Das Hotel ist nur wenige Gehminuten vom Strand entfernt. Das Personal war sehr freundlich und hilfsbereit. Wir würden wieder hier übernachten. Sehr geehrter Herr Blümel, Vielen Dank für Ihre Bewertung. Es freut uns sehr, dass Sie sich für den Aufenthalt bei uns im Haus entschieden haben. Wir hoffen, Sie bald wieder bei uns begrüßen zu dürfen. Mit freundlichen Grüßen Ihr Hotelmanager Familie Roth und Ihr Team Sehr geehrter Herr Blümel,

C2 Wir waren in diesem Hotel. Es ist ein Familienhotel. Der Altersdurchschnitt ist gemischt. Die Kinder haben wir nur einmal in einem Kinderclub besucht. Die Animation war gut. Es gab keine Musik. Man konnte immer etwas unternehmen. Das Essen war gut. Es gab auch immer ein Salatbuffet. Wir haben es aber nicht genutzt. Das Frühstück war gut. Es gab verschiedene Brotsorten, verschiedene Wurstsorten, verschiedene Käse, Marmelade, Honig, Müsli, Joghurt, Eier, Wurst, verschiedene Brotsorten, verschiedene Brötchen, Eier

C3 Wir waren in diesem Hotel. Das Personal war sehr freundlich und hilfsbereit. Die Zimmer wurden jeden Tag gereinigt. Die Animation war auch sehr nett und hilfsbereit. Das Essen war auch sehr gut. Es gab immer genug Obst und Gemüse. Es gab immer ausreichend Auswahl an warmen Speisen. Auch die Nachspeisen waren immer lecker. Das Zimmer war immer sehr sauber und das Personal war sehr nett und hilfsbereit. Die Animation war auch sehr nett und hilfsbereit. Das Essen war auch immer sehr lecker und auch die Auswahl war sehr gut. Das Personal ist sehr nett

D1 Wir waren in diesem Hotel. Die Zimmer waren sehr schön und sauber. Das Personal war sehr freundlich und hilfsbereit. Das Frühstück war sehr gut und abwechslungsreich. Das..." "Sehr gutes Hotel, sehr gute Lage. Alles ist fußläufig erreichbar. Sehr freundliches Personal. Sehr gutes Frühstück. Wir kommen gerne wieder. Vielen

Dank für Ihre Empfehlung! Das Hotel liegt sehr zentral, sehr ruhig. Sehr freundliches Personal. Wir haben uns sehr wohl gefühlt. Das Hotel ist sehr gut gelegen. Der Service war sehr gut. Die Zimmer sind sehr

D2 Wir waren in diesem Hotel. Im ersten Moment war das Hotel schön, aber dann haben wir uns auf der Terrasse in der Mitte mit den vielen Mücken aufgehalten. Die Einrichtung war schon alt und altbacken. Wir haben es nicht genutzt. Es war sehr laut und laut. Das Zimmer war sehr klein. Das Bad war dreckig. Die Dusche war dreckig und auch die Toilette war dreckig. Es gab keine Klimaanlage. Wir haben uns beschwert und wurden sogar auf den Nachbarflur geschickt. Wir haben das Hotel gewechselt. Die Mitarbeiter an der

D3 Wir waren in diesem Hotel. Das Essen war eine Zumutung. Es gab nur eine Sorte Fleisch, das nicht durchgegart war. Das Fleisch war so trocken, dass es aussah als wäre es schon aufgeweicht. Es gab jeden Tag das selbe. Die Atmosphäre war sehr schlecht. Es gab keinen Service. Es gab nur einen Kellner, der sich um die Gäste kümmerte. Der war auch sehr unfreundlich. Es gab kein warmes Essen. Es gab nur eine Sorte Wurst. Das Brot war eine Zumutung. Es gab kein frisches Brot

E1 Wir waren in diesem Hotel. Die Zimmer sind sehr groß und sauber. Die Lage ist super. Sauberkeit und Wellness sind sehr gut. Das Personal ist sehr freundlich und hilfsbereit. Das Essen ist sehr gut und abwechslungsreich. Das Personal ist sehr hilfsbereit und immer freundlich. Das Zimmer ist sehr groß und sauber. Das Personal ist sehr freundlich und hilfsbereit. Das Zimmer ist sehr groß und sauber. Das Personal ist sehr groß und sauber. Das Zimmer ist sehr groß und sauber. Das Zimmer ist sehr groß und sauber. Das Zimmer ist sehr groß und sauber. Das Personal ist sehr hilfsbereit und hilfsbereit. Das Zimmer ist sehr groß und sauber. Das Zimmer ist sehr groß und sauber. Das Zimmer ist sehr groß und sauber. Das Personal ist sehr groß und hilfsbereit'

E2 Wir waren in diesem Hotel. Die Lage war super, Sauberkeit gut und Wellness pur. Es war ein perfekter Urlaub, die Zimmer waren in allen Bereichen sehr sauber. Wir werden gerne wiederkommen!Das Hotel ist sehr gepflegt und der Strand war auch immer schön gepflegt. Der Weg zum Strand war auch sehr schön, der Strand war sehr sauber und es gab viele Liegen mit Sonnenschirm. Das Zimmer war in Ordnung und die Handtücher wurden gewechselt. Ein großes Dankeschön an die Rezeption, ich habe immer an die Hand genommen. Das Essen war frisch und

E3 Wir waren in diesem Hotel. Das Hotel ist sehr groß und gut ausgestattet. Die Zimmer sind sehr sauber und das Personal ist sehr freundlich und hilfsbereit. Das Essen ist sehr gut und abwechslungsreich. Die Lage ist sehr schön und das Hotel ist in

der Nähe von Sauberkeit und Wellness. Wir haben uns sehr wohl gefühlt und werden in Zukunft wieder kommen. Wir würden das Hotel auf jeden Fall weiter empfehlen. Das Personal ist sehr freundlich und hilfsbereit. Wir haben uns sehr wohl gefühlt und würden jederzeit wiederkommen. Es gibt eine kleine Auswahl an Getränken. Das

F1 Wir waren in diesem Hotel. Das Essen war ungenießbar. Die Aussicht auf den Pool war sehr schlecht. Fitnessraum war auch nicht vorhanden. Schwimmbad war sehr klein und sehr schmutzig. Die Liegen waren sehr dreckig. Die Handtücher wurden nur einmal gewechselt. Das Wasser im Pool war sehr kalt. Die Handtücher wurden nur einmal gewechselt. Das Personal war sehr unfreundlich. Das Essen war sehr schlecht. Das Frühstück war ungenießbar. Das Brot war sehr trocken. Das Brot war sehr trocken. Das Brot war sehr trocken. Das Brot war sehr trocken.

F2 Wir waren in diesem Hotel. Das Essen war sehr schlecht. Es war sehr kalt. Das Personal war sehr unfreundlich und der Pool war auch nicht beheizt. Die Aussicht auf Schwimmbad und Fitnessraum war echt schlecht. Wir hatten einen tollen Ausblick auf den Fluss, der sich in die Höhe bewegte. Das Zimmer war klein, schmutzig und alt. Die Bettwäsche wurde jeden Tag gewechselt. Wenn das Wetter zu heiß wurde, musste man die Kleidung ausziehen, da diese nass war. Das Bad war dreckig. Das Wasser wurde auch nicht gewechselt.

F3 Wir waren in diesem Hotel. Das Essen war schlecht. Es gab immer das gleiche. Das Personal war sehr unfreundlich. Die Zimmerreinigung war auch nicht gut. Die Aussicht auf das Meer war sehr schlecht. Das Schwimmbad war sehr klein und sehr schmutzig. Fitnessraum war auch nicht vorhanden. Das Hotel ist sehr veraltet. Die Sauberkeit der Zimmer ist auch nicht sehr gut. Das Bad ist sehr alt und schimmlig. Die Fenster sind nur für Erwachsene und Kinder geeignet. Die Handtücher werden nicht gewechselt. Die Betten sind sehr durchgelegen.

# Appendix F Likert Scale Interpretation, Categories and Items

Table 22
Explanation of Likert Scale.

Scale	Description	Mean Range	Meaning
1	Strongly Disagree	1.00 - 1.79	Very Low
2	Disagree	1.80 - 2.59	Low
3	Neutral	2.60 - 3.39	Neutral
4	Agree	3.40 - 4.19	High
5	Strongly Agree	4.20 - 5.00	Very High

Table 23
Category and Items in the Survey.

Category	Item	Scale
Sentiment The text matches sentiment.	• Sentiment: Dieser Text ist positive. (The text is positive)	1-5 (strong disagree - strong agree)
Fluency The text is fluent	Gramaticallity: Dieser Text ist frei von Rechtschreib- und Grammatikfehlern. (This text is free of spelling and grammatical errors.)      Structure: Dieser Text ist gut struk	1-5 (strong disagree - strong agree)
	• Structure: Dieser Text ist gut strukturiert. (This text is well structured.)	
	• Understablility: Dieser Text ist leicht verständlich. (This text is easy to understand.)	
	• Nativity: Ein Muttersprachler könnte den Text genauso geschrieben haben. (A native speaker could have written the text exactly the same way.)	
Coherence the text is coherent	<ul> <li>Sense: Dieser Text ergibt Sinn. (This text makes sense.)</li> <li>Transitions: Die Übergänge in dem Text sind gut geschrieben. (The transitions in the text are well written.)</li> </ul>	1-5 (strong disagree - strong agree)

# Appendix G Functions for SLOR and Coherence Score

#### Code Listing 7

SLOR function.Note: Own Creation.

```
def slor_score(text):
text=text.lstrip()
  slor_scores=[]
  doc = nlp(text)
  # Extract sentences
  sentences = [sent.text for sent in doc.sents]
  # Calculate word frequencies
  for sentence in sentences:
   tokenized_input = tokenizer_ref.encode(sentence, return_tensors="pt",
     truncation=True)
   sentence_length = len(tokenized_input[0])
12
13
  loss, logits = model_ref(tokenized_input, labels=tokenized_input)[:2]
14
   softmax = torch.nn.Softmax(dim=-1)
   probabilities = softmax(logits)[0]
16
17
   # Calculate sentence probability by multiplying token probabilities
   sentence_probability = 1.0
   for token_probability in probabilities:
   max_token_probability = token_probability.max().item()
   sentence_probability *= max_token_probability
22
23
   words = re.findall(r'\b\w+\b', sentence.lower())
24
   word_frequencies = Counter(words)
   total_words = len(words)
27
   # Calculate probabilities for each word
   word_probabilities = {word: count / total_words for word, count in
     word_frequencies.items()}
  # Display probabilities for each word
31
  for word, prob in word_probabilities.items():
  unigram=unigram*prob
```

```
if total_words!=0:
slor=math.log(sentence_probability)/total_words-math.log(unigram)/
    total_words
slor_scores.append(slor)

return np.mean(slor_scores)
```

#### Code Listing 8

Coherence Score. Note: Adapted from Kapadia (2019).

```
1 def lda_coherence_score(text):
      stop_words = set(stopwords.words('german'))
      data_words = nltk.word_tokenize(text, language='german')
      data_words = [word for word in data_words if word.lower() not in
     stop_words]
      bigrams = gensim.models.Phrases([data_words], min_count=5, threshold
6
     =100)
      bigram mod = gensim.models.phrases.Phraser(bigrams)
      data_bigrams = [bigram_mod[data_words]]
      nlp = spacy.load("de_core_news_sm", disable=['parser', 'ner'])
      data_lemmatized = [
          [token.lemma_ for token in nlp(word)] for word in data_bigrams[0]
      1
13
14
      id_to_word = corpora.Dictionary(data_lemmatized)
      corpus = [id_to_word.doc2bow(text) for text in data_lemmatized]
16
17
      lda_model = gensim.models.LdaModel(corpus=corpus,
18
                                                id2word=id_to_word,
19
                                                num_topics=4,
20
                                                random_state=100,
                                                chunksize=100,
22
                                                passes=20,
                                                per_word_topics=True)
25
      coherence_model = CoherenceModel(model=lda_model, texts=
26
     data lemmatized, dictionary=id to word, coherence='c v')
      coherence_score = coherence_model.get_coherence()
28
      return coherence score
```

# Appendix H Evaluation of Survey's Items

Table 24
The Text is Positive.

	1	2	3	
A	key: negative 3.64 (1.15)	key: positive 4.43 (0.95)	key: mixed 3.57 (1.09)	sent: positive
В	key: negative 5.00 (0.00)	key: positive 5.00 (0.00)	key: mixed 5.00 (0.00)	sent: negative
С	GPT-2 4.21 (1.42)	SFT1 3.86 (0.95)	SFT1RL1 4.79 (0.43)	sent: positive
D	GPT-2 1.36 (0.63)	SFT1 4.93 (0.27)	SFT1RL1 5.0 (0.0)	sent: negative
Е	Greedy Search 4.29 (1.14)	Top k (15) 4.79 (0.58)	Top p (0.5) 4.36 (0.63)	sent: positive key: nouns
F	Greedy Search 5.00 (0.00)	Top k (15) 4.71 (0.47)	Top p (0.5) 4.79 (0.80)	sent: negative key: nouns

Table 25
This Text is Free of Spelling and Grammatical Errors.

	1	2	3	
A	key: negative 2.29 (1.14)	key: positive 1.93 (1.49)	key: mixed 2.35 (1.15)	sent: positive
В	key: negative 3.07 (1.43)	key: positive 1.57 (0.85)	key: mixed 1.71 (1.21)	sent: negative
С	GPT-2 4.57 (0.51)	SFT1 4.00 (1.11)	SFT1RL1 4.29 (1.14)	sent: positive
D	GPT-2 2.79 (1.37)	SFT1 2.64 (1.60)	SFT1RL1 4.21 (0.69)	sent: negative
Е	Greedy Search 3.71 (1.43)	Top k (15) 3.00 (1.11)	Top p (0.5) 3.07 (1.54)	sent: positive key: nouns
F	Greedy Search 3.07 (1.59)	Top k (15) 3.57 (0.94)	Top p (0.5) 4.07 (0.83)	sent: negative key: nouns

Table 26
This Text is Well Structured.

	1	2	3	
A	key: negative 2.14 (0.95)	key: positive 2.14 (1.17)	key: mixed 2.5 (0.94)	sent: positive
В	key: negative 2.00 (0.88)	key: positive 1.64 (0.93)	key: mixed 1.36 (0.50)	sent: negative
С	GPT-2 3.57 (1.55)	SFT1 3.14 (1.17)	SFT1RL1 2.5 (1.22)	sent: positive
D	GPT-2 1.86 (0.77)	SFT1 2.14 (1.16)	SFT1RL1 3.29 (1.20)	sent: negative
Е	Greedy Search 1.5 (0.76)	Top k (15) 3.36 (1.22)	Top p (0.5) 2.5 (0.94)	sent: positive key: nouns
F	Greedy Search 1.86 (1.16)	Top k (15) 2.14 (1.10)	Top p (0.5) 3.36 (1.08)	sent: negative key: nouns

Table 27
This Text is Easy to Understand.

	1	2	3	
A	key: negative 3.50 (0.85)	key: positive 3.79 (1.19)	key: mixed 2.93 (1.21)	sent: positive
В	key: negative 2.64 (1.15)	key: positive 2.79 (1.19)	key: mixed 2.64 (1.28)	sent: negative
С	GPT-2 4.29 (1.10)	SFT1 3.78 (0.97)	SFT1RL1 4.21 (0.80)	sent: positive
D	GPT-2 3.14 (1.29)	SFT1 4.29 (0.91)	SFT1RL1 3.14 (1.29)	sent: negative
E	Greedy Search 4.29 (0.91)	Top k (15) 3.79 (1.12)	Top p (0.5) 3.93 (0.73)	sent: positive key: nouns
F	Greedy Search 3.5 (1.09)	Top k (15) 2.79 (0.97)	Top p (0.5) 4.07 (1.07)	sent: negative key: nouns

Table 28
A Native Speaker Could Have Written the Text Exactly the Same Way.

	1	2	3	
A	key: negative 1.71 (0.73)	key: positive 2.29 (1.14)	key: mixed 1.64 (1.08)	sent: positive
В	key: negative 2.00 (1.18)	key: positive 1.64 (0.84)	key: mixed 1.36 (0.74)	sent: negative
С	GPT-2 4.14 (1.10)	SFT1 2.94 (1.49)	SFT1RL1 3.00 (1.24)	sent: positive
D	GPT-2 2.36 (0.93)	SFT1 1.64 (0.63)	SFT1RL1 3.36 (1.15)	sent: negative
Е	Greedy Search 1.64 (1.00)	Top k (15) 2.93 (1.54)	Top p (0.5) 2.50 (1.29)	sent: positive key: nouns
F	Greedy Search 2.21 (1.19)	Top k (15) 2.14 (1.29)	Top p (0.5) 3.43 (1.28)	sent: negative key: nouns

Table 29
This Text Makes Sense.

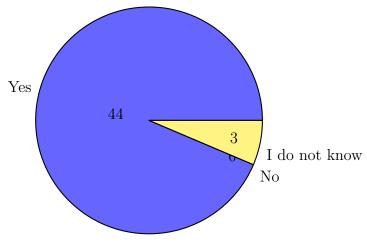
	1	2	3	
A	key: negative 3.07 (1.07)	key: positive 3.57 (1.10)	key: mixed 2.64 (0.93)	sent: positive
В	key: negative 2.43 (1.15)	key: positive 2.79 (1.05)	key: mixed 2.00 (1.11)	sent: negative
С	GPT-2 3.79 (1.58)	SFT1 3.29 (1.07)	SFT1RL1 3.79 (0.59)	sent: positive
D	GPT-2 3.00 (0.96)	SFT1 2.57 (1.22)	SFT1RL1 3.64 (1.34))	sent: negative
Е	Greedy Search 2.79 (0.89)	Top k (15) 3.57 (1.09)	Top p (0.5) 3.50 (0.76)	sent: positive key: nouns
F	Greedy Search 3.21 (1.12)	Top k (15) 2.64 (1.01)	Top p (0.5) 3.50 (1.16)	sent: negative key: nouns

Table 30
The Transitions in the Text are Well Written.

	1	2	3	
A	key: negative 1.86 (1.03)	key: positive 2.14 (1.10)	key: mixed 1.92 (0.73)	sent: positive
В	key: negative 1.79 (1.05)	key: positive 1.50 (0.76)	key: mixed 1.57 (1.02)	sent: negative
С	GPT-2 2.93 (1.33)	SFT1 3.21 (0.89)	SFT1RL1 2.64 (1.28)	sent: positive
D	GPT-2 1.86 (0.84)	SFT1 1.64 (0.84)	SFT1RL1 2.86 (1.29)	sent: negative
Е	Greedy Search 2.00 (1.18)	Top k (15) 2.64 (1.28)	Top p (0.5) 2.43 (1.09)	sent: positive key: nouns
F	Greedy Search 1.79 (1.12)	Top k (15) 2.21 (0.89)	Top p (0.5) 2.93 (0.92)	sent: negative key: nouns

# Appendix I Influence of Human Intervention on Text Quality

Figure 22
Can Additional Human Intervention Improve the Text Quality?



Note: Own Creation